Data Warehouse

Transfermarkt

Manuel Caballero Bonilla
Alberto Lillo García

ÍNDICE

01
RESUMEN PROPUESTA
Introducción, Objetivos Generales y ¿Por Qué?

02
DESARROLLO
Diseño DW (Modelado) y Procesamiento de Datos.

03
RESULTADOS
Consultas OLAP.

04
INSIGHTS
Visualización y Minería de Datos.

05
CONCLUSIONES
Conclusiones.

01

RESUMEN PROPUESTA

Introducción, Objetivos Generales y ¿Por Qué?

INTRODUCCIÓN
OBJETIVOS GENERALES

DATA WAREHOUSE

¿ POR QUÉ ESTE DATASET ?

5,7 M

2012 – 2025

Archivo	Descripción resumida	Columnas ejemplo
Appearances.csv	Aparición de jugadores por club. Una fila por aparición.	Appearance_id, game_id, player_id, player_club_id …
Club_games.csv	Resultados de partidos por clubes.	Game_id, club_id, own_goals, opponent_id…
Clubs.csv	Información de todos los clubes de las ligas. Una fila por club.	Club_id, name, domestic_competition…
Competitions.csv	Detalles de ligas y torneos.	Competition_id, name, type, domestic_league…
Game_events.csv	Eventos en partidos relacionados con club y jugador.	Game_id, minute, type, club_id, player_id …
Game_lineups.csv	Alineaciones por partido.	Game_id, player_id, positition, type…
Games.csv	Datos de partidos (fechas, puntuaciones, …)	Game_id, season, home_goals…
Player_valuations.csv	Valoraciones de mercado históricas	Player_id, date, market_value…
Players.csv	Perfiles de jugadores (edad, posición…)	Player_id, name, position…
Transfers.csv	Historial de transferencias	Player_id, from_club_id, transfer_fee…

02 DESARROLLO

Diseño DW (Modelado) y Procesamiento de Datos.

DISEÑO DW (MODELADO)

- **Dimensión Players.**
(Basada en players.csv)

- **Dimensión Clubs.**
(Basada en clubs.csv)

- **Dimensión Competitions.**
(Basada en competitions.csv)

- **Dimensión Games.**
(Basada en games.csv)

- **Dimensión Date.**
(Tabla generada)

Nombre Tabla de Hechos	Intención	Formación	PK	Granularidad	FK's	Atributos Degenerados	Medidas
Fact Games	Resumen de lo ocurrido en cada partido.	Unión de *games*.csv y *club_games*.csv con desnormalización.	ID del partido (PK y FK a Dim Games)	Un registro por partido.	*game_id, competition_id, home_club_id, away_club_id, date_id.*	-	*home_club_goals, away_club_goals, is_win (Para el equipo Local)*
Fact Appearances	Registra el rendimiento del jugador en cada partido.	Combinación de *appearances*.csv y *game_lineups*.csv con desnormalización.	ID de *apperarance*	Un registro por jugador en un partido.	*game_id, player_id, club_id, competition_id, date_id.*	*type* (titular o suplente), *position* (posición específica jugada ese día), *team_captain* …	*minutes_played, goals, assists, yellow_cards, red_cards*
Fact Game Events	Registra el rendimiento del jugador en cada partido.	Basada en *game_events*.csv	ID de ese suceso	Un registro por evento dentro de un partido.	*game_id, club_id, player_id, player_in_id* (si es sustitución), *player_assist_id* (si es gol), *date_id.*	*type* (tipo de evento), *description.*	*minute*
Fact Transfers	Representa los traspasos de jugadores.	Basada en *transfers*.csv.	*transfer_id* (atributo auto incremental generado)	Un registro por traspaso.	*player_id, from_club_id, to_club_id, transfer_date_id.*	*transfer_season.*	*transfer_fee, market_value_in_eur*
Fact Player Valuations	Histórico del valor de mercado de un jugador.	Basada en *player_valuations*.csv.	*valuation_id* (atributo auto incremental generado)	Un registro por jugador, club y fecha.	*player_id, club_id* (como *current_club_id*), *competition_id, date_id.*	-	*market_value_in_eur*

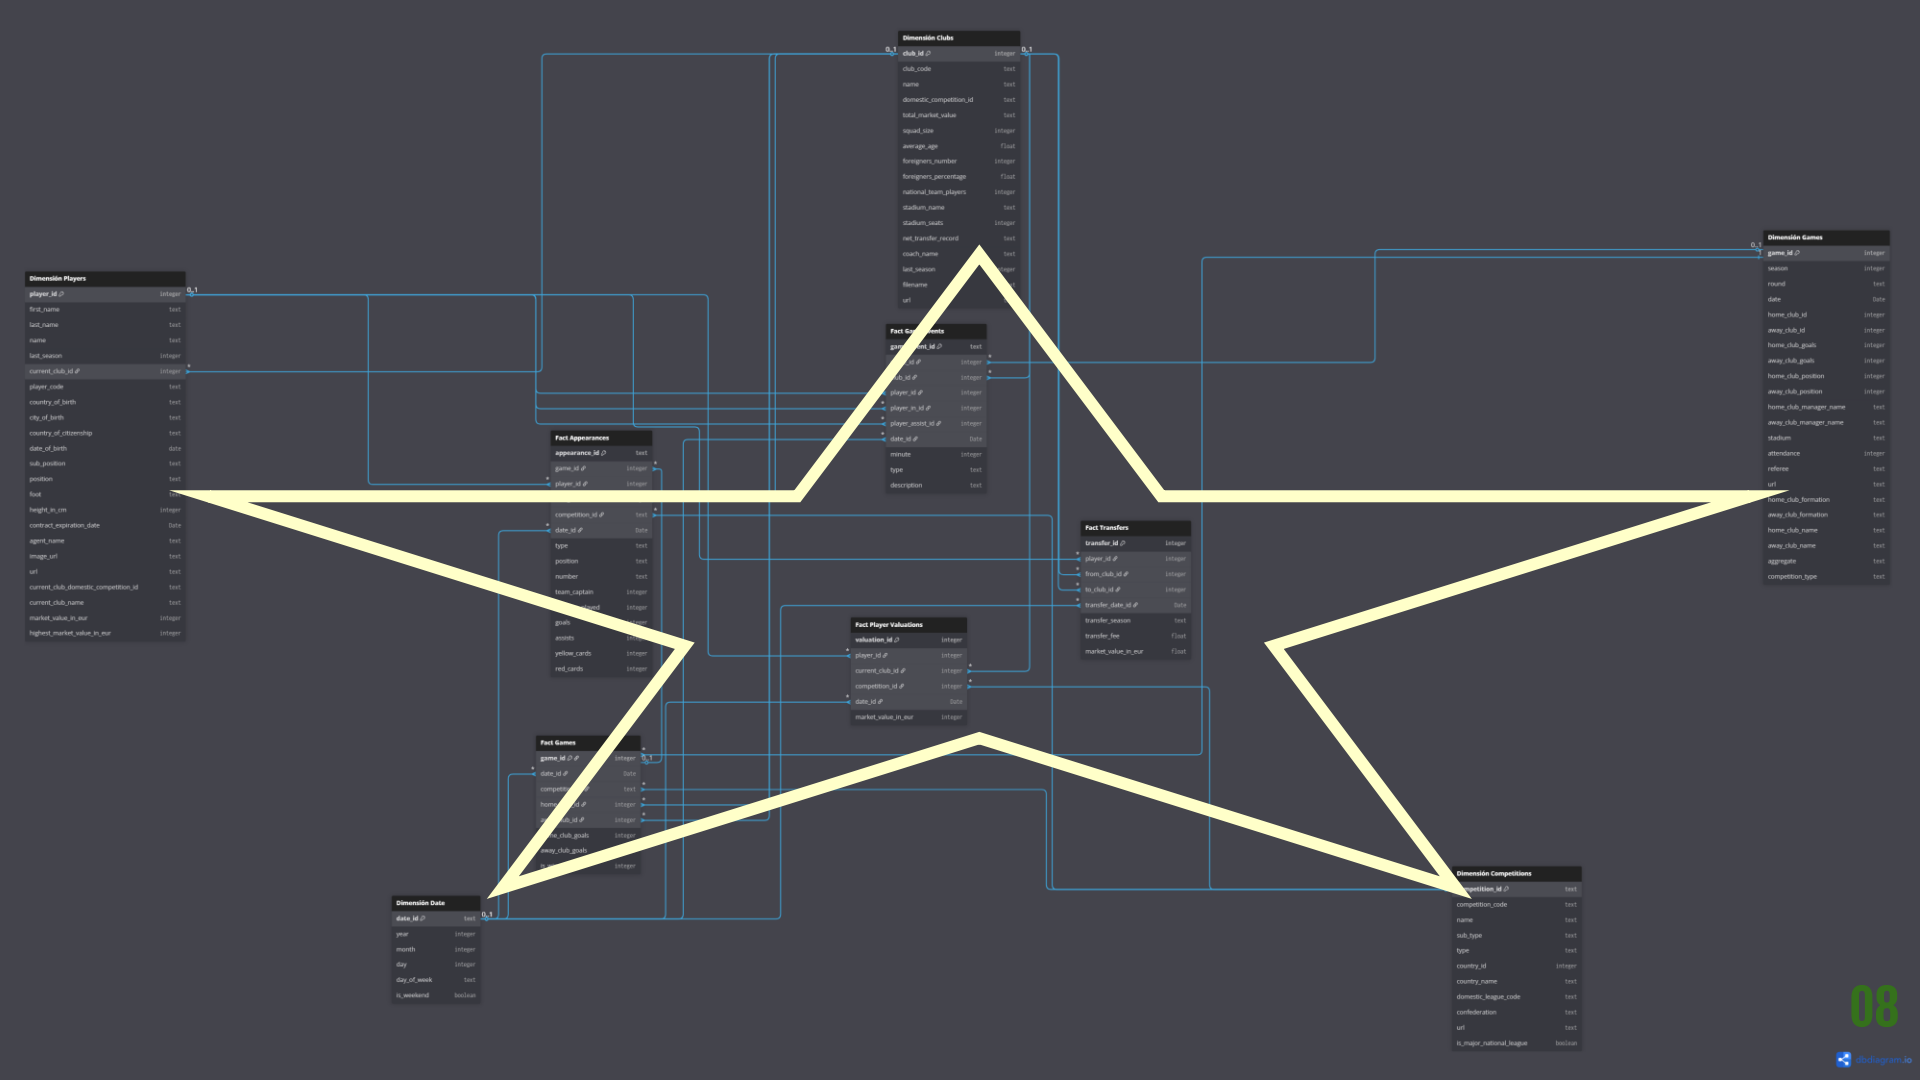
Dimensión Clubs
club_id integer
club_code text
name text
domestic_competition_id text
total_market_value text
squad_size integer
average_age float
foreigners_number integer
foreigners_percentage float
national_team_players integer
stadium_name text
stadium_seats integer
net_transfer_record text
coach_name text
last_season integer
filename text
url text
Dimensión Games
game_id integer
season integer
round text
date Date
home_club_id integer
away_club_id integer
home_club_goals integer
away_club_goals integer
home_club_position integer
away_club_position integer
home_club_manager_name text
away_club_manager_name text
stadium text
attendance integer
referee text
url text
home_club_formation text
away_club_formation text
home_club_name text
away_club_name text
aggregate text
competition_type text
Dimensión Players
player_id integer
first_name text
last_name text
name text
last_season integer
current_club_id integer
player_code text
country_of_birth text
city_of_birth text
country_of_citizenship text
date_of_birth date
sub_position text
position text
foot text
height_in_cm integer
contract_expiration_date Date
agent_name text
image_url text
url text
current_club_domestic_competition_id text
current_club_name text
market_value_in_eur integer
highest_market_value_in_eur integer
Fact Appearances
appearance_id text
game_id integer
player_id integer
competition_id text
date_id Date
type text
position text
number text
team_captain integer
yellow_cards integer
red_cards integer
Fact Transfers
transfer_id integer
player_id integer
from_club_id integer
to_club_id integer
transfer_date_id Date
transfer_season text
transfer_fee float
market_value_in_eur float
Fact Player Valuations
valuation_id integer
player_id integer
current_club_id integer
competition_id integer
date_id Date
market_value_in_eur integer
Fact Games
game_id integer
date_id Date
away_club_goals integer
Dimensión Date
date_id text
year integer
month integer
day integer
day_of_week text
is_weekend boolean
Dimensión Competitions
competition_id text
competition_code text
name text
sub_type text
type text
country_id integer
country_name text
domestic_league_code text
confederation text
url text
is_major_national_league boolean
0..1
dbdiagram.io

08

PROCESAMIENTO DE DATOS

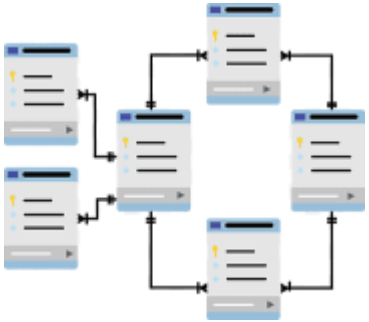

PostgreSQL

ddl_dwh_schema.sql

ARQUITECTURA MODULAR DEL SISTEMA ETL

Nombre Script	Descripción
generate_dim_date.py	Generación programática de la dimensión temporal desde el año 2000 hasta 2030, sin dependencias de archivos .CSV, incluyendo atributos derivados como trimestre, día de la semana e indicador de fin de semana.
etl_dim_competitions.py	Carga de competiciones desde competitions.csv.
etl_dim_clubs.py	Carga de clubes desde clubs.csv, más inserción del registro centinela club_id = -1
etl_dim_players.py	Carga de jugadores desde players.csv, aplicando cálculo de edad a partir de la fecha de nacimiento, más registro centinela player_id = -1.
etl_dim_games.py	Carga de partidos desde games.csv, actuando como dimensión degenerada con atributos descriptivos propios.

Nombre Script	Descripción
etl_fact_games.py	Desnormalización de *games.csv* y *club_games.csv*, generando métricas agregadas.
etl_fact_appearances.py	Fusión de *appearances.csv* y *game_lineups.csv* mediante LEFT JOIN.
etl_fact_game_events.py	Carga de eventos minuto a minuto desde *game_events.csv* (goles, tarjetas, sustituciones).
etl_fact_transfers.py	Transformación de *transfers.csv* con *parsing* de valores monetarios en formato texto ("€50.00m" → 50000000) y normalización de temporadas.
etl_fact_player_valuations.py	Carga de valoraciones históricas desde *player_valuations.csv* con interpolación temporal.

Nombre Script	Descripción
run_etl_full.py	Coordinador maestro que ejecuta los 10 scripts ETL en orden de dependencias, implementando truncado previo de tablas (*truncate_all_tables*()), *logging* completo y gestión centralizada de errores.

Nombre Script	Descripción
config.py	Centraliza la conexión *PostgreSQL* mediante *SQLAlchemy* (*get_engine*()), define rutas absolutas a los 10 archivos .CSV y establece *BATCH_SIZE*=10000 para la optimización de inserciones por lotes.
null_handler.py	Implementa la estrategia de *Kimball*[1][2][3] de tratamiento de valores ausentes mediante seis constantes tipadas y dos funciones de aplicación/validación.

ESTRTAEGIA DE TRATAMIENTO DE NULLS

Categoría	Valor por defecto	Aplicación
Texto en dimensiones	'N/A'	Atributo nunca registrado en la fuente.
Texto en hechos	'Unknown'	Detalle del evento no capturado.
Medida agregable	0	*goals, assists, minutes_played*, etc; ausencia = no ocurrió
Atributo clasificador	-1	*minute, attendance, squad_size*; valor imposible en el dominio
Valor monetario	-1	*transfer_fee, market_value_in_eur;* distingue "gratis" (0) de "sin dato" (-1)
FK opcional	-1	*player_assist_id, from_club_id*; apunta al registro centinela
Booleano	False	*is_major_national_league, team_captain*
Fecha desconocida	'1900-01-01'	*date_of_birth* sin dato.
Fecha sin vencimiento	'9999-12-31'	*contract_expiration_date* indefinido.

- **Dim_clubs:** *club_id* = 1, *club_name* = '*Desconocido*'
- **Dim_players:** *player_id* = -1, *player_name* = '*Desconocido*'

PROCESO DE CARGA Y RESULTADOS CUANTITATIVOS

Tabla	Registros Cargados	Fuente Principal
dim_date	11.323	Generación programática
dim_competitions	44	competitions.csv
dim_clubs	440	clubs.csv + centinela
dim_players	32.602	players.csv + centinela
dim_games	58.495	games.csv
fact_games	58.495	games.csv + club_games.csv
fact_appearances	1.628.836	appearances.csv + game_lineups.csv
fact_game_events	809.989	game_events.csv
fact_transfers	79.594	transfers.csv
fact_player_valuations	496.606	player_valuations.csv

Registros Originales del *Dataset*: Más de 5’7 Millones.
Registros Cargados en la Fase *Load* del ETL: *3.176.424.*

03

RESULTADOS

Consultas OLAP.

ESTRUCTURA DEL CORPUS DE CONSULTAS

Bloque	Secciones	Consultas	Descripción
OLAP puras	1 - 7	23	Una operación por sección, máximo didactismo.
Análisis combinados	8	5	Varias operaciones integradas por caso de uso.
Consultas estrella	9	10	*Insights* directamente presentables.
Extensiones	10 – 12	11	Auditoría técnica, jugadores individuales y equipos.
Total		49	

04 INSIGHTS

Visualización y
Minería de Datos.

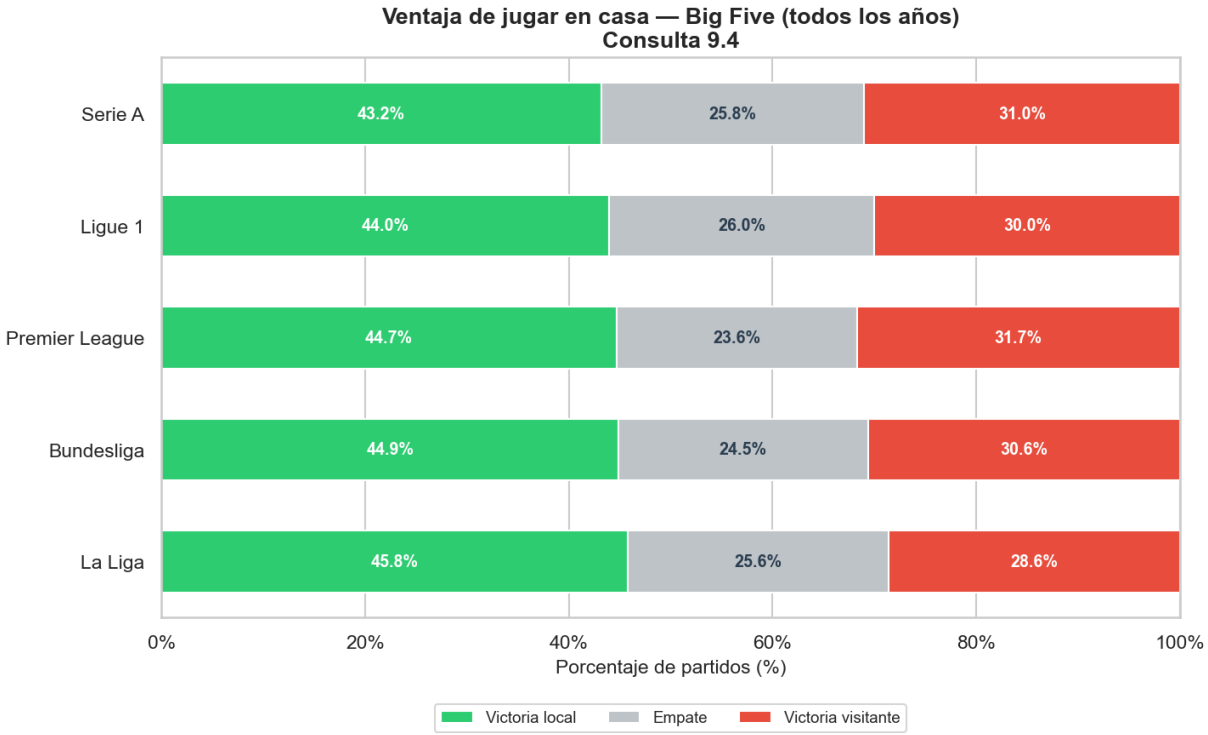

Goles promedio por partido

Liga	Local	Visitante
La Liga	1.52	1.13
Bundesliga	1.69	1.34
Premier League	1.55	1.25
Ligue 1	1.48	1.16
Serie A	1.51	1.24

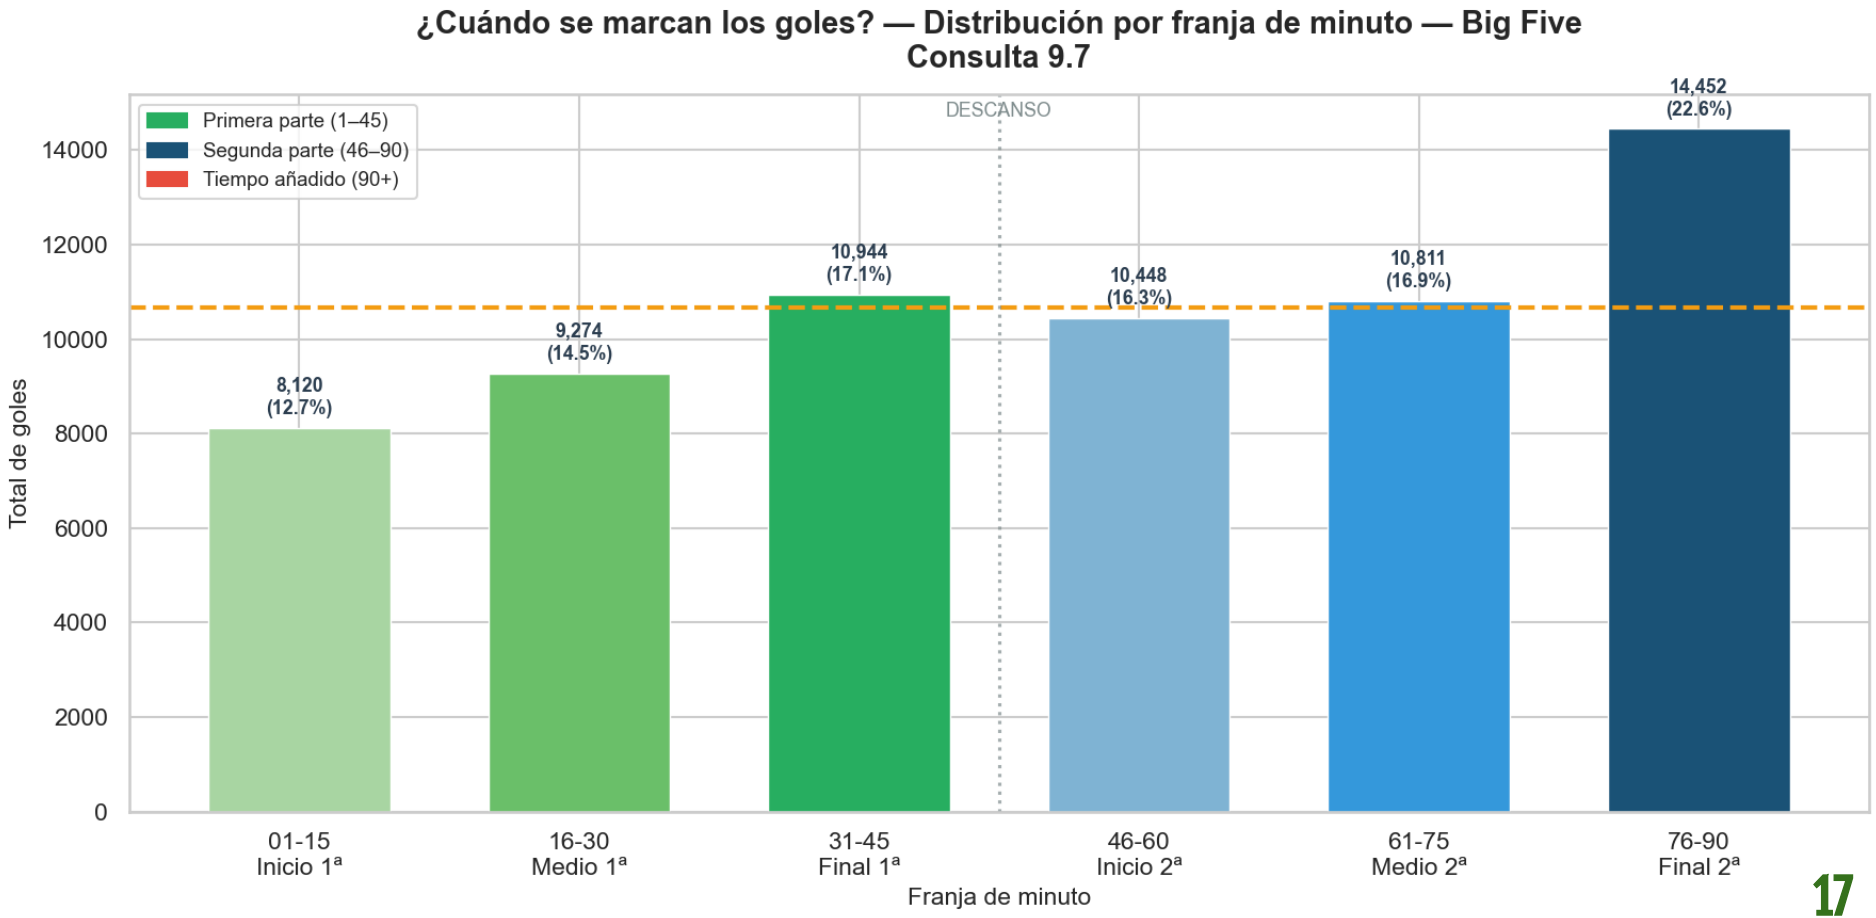
¿Cuándo se marcan los goles? — Distribución por franja de minuto — Big Five
Consulta 9.7
Primera parte (1–45)
Segunda parte (46–90)
Tiempo añadido (90+)
DESCANSO
8,120
(12.7%)
9,274
(14.5%)
10,944
(17.1%)
10,448
(16.3%)
10,811
(16.9%)
14,452
(22.6%)
Total de goles
0
2000
4000
6000
8000
10000
12000
14000
01-15
Inicio 1ª
16-30
Medio 1ª
31-45
Final 1ª
46-60
Inicio 2ª
61-75
Medio 2ª
76-90
Final 2ª
Franja de minuto

Evolución e inflación del mercado de fichajes 2012–2025
Consulta 9.9 · Precio medio, mediana y variación interanual

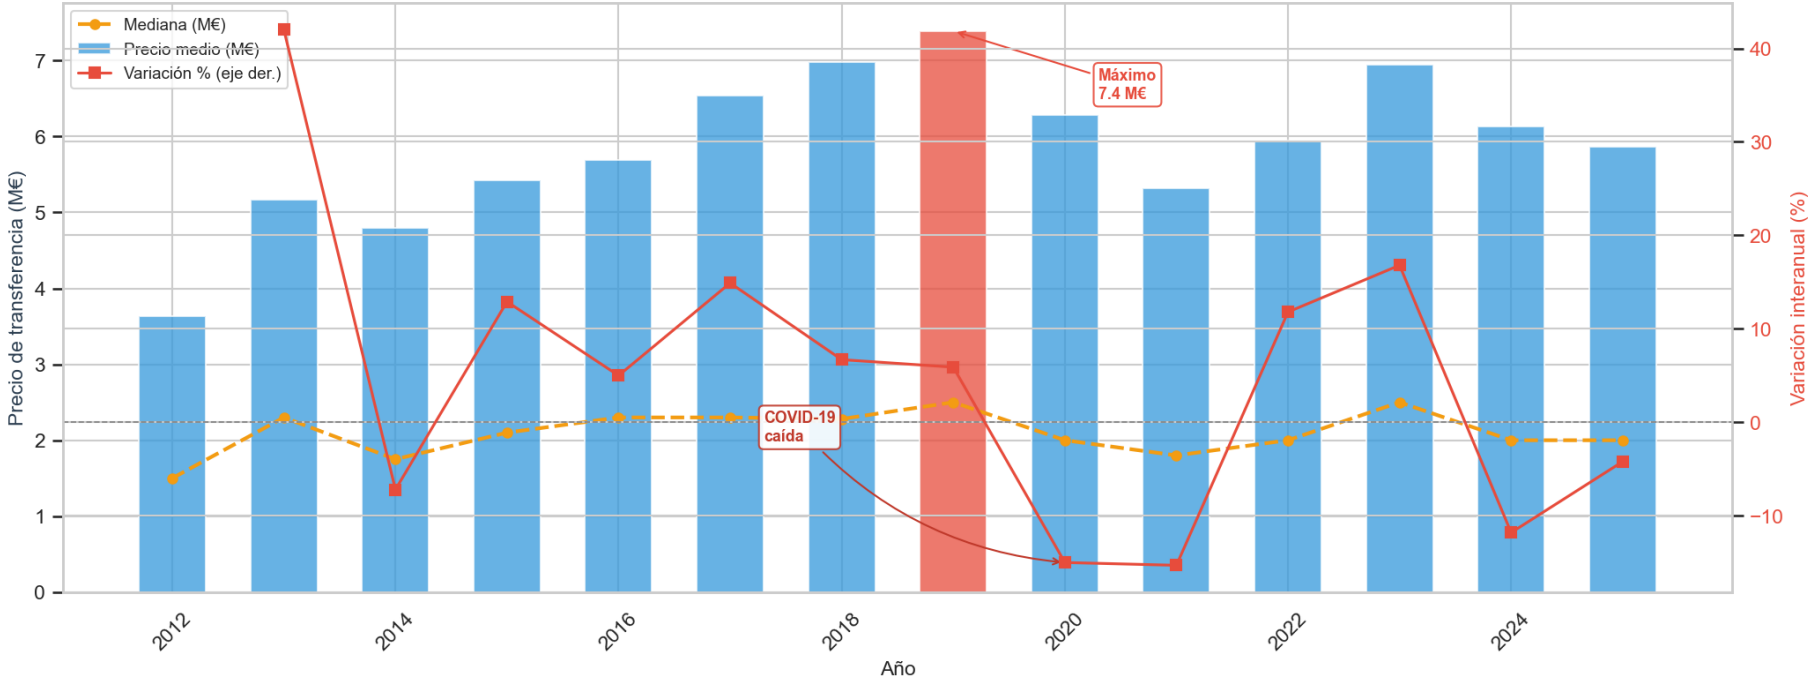

Pichichi — Máximo goleador por temporada en cada liga · 2015–2024
Consulta 9.5

Temporada	La Liga	Premier League	Serie A	Bundesliga	Ligue 1
2015	Suárez (40)	Kane (25)	Higuaín (36)	Lewandowski (30)	Ibrahimović (38)
2016	Messi (37)	Kane (29)	Džeko (29)	Aubameyang (31)	Cavani (35)
2017	Messi (34)	Salah (32)	Icardi (29)	Lewandowski (29)	Cavani (28)
2018	Messi (36)	Aubameyang (22)	Quagliarella (26)	Lewandowski (22)	Mbappé (33)
2019	Messi (22)	Vardy (19)	Immobile (29)	Lewandowski (34)	Yedder (18)
2020	Messi (33)	Kane (29)	Ronaldo (36)	Lewandowski (41)	Mbappé (27)
2021	Benzema (27)	Salah (23)	Immobile (27)	Lewandowski (35)	Mbappé (28)
2022	Lewandowski (23)	Haaland (36)	Osimhen (26)	Nkunku (16)	Mbappé (29)
2023	Dovbyk (24)	Haaland (27)	Martínez (24)	Kane (36)	Mbappé (27)
2024	Lewandowski (25)	Salah (27)	Retegui (22)	Kane (23)	Dembélé (21)

Goles del Pichichi: 40, 35, 30, 25, 20

¿Más inversión = más victorias? — Big Five (2018–2024)
Consulta 12.2 · Top 30 clubs por inversión total

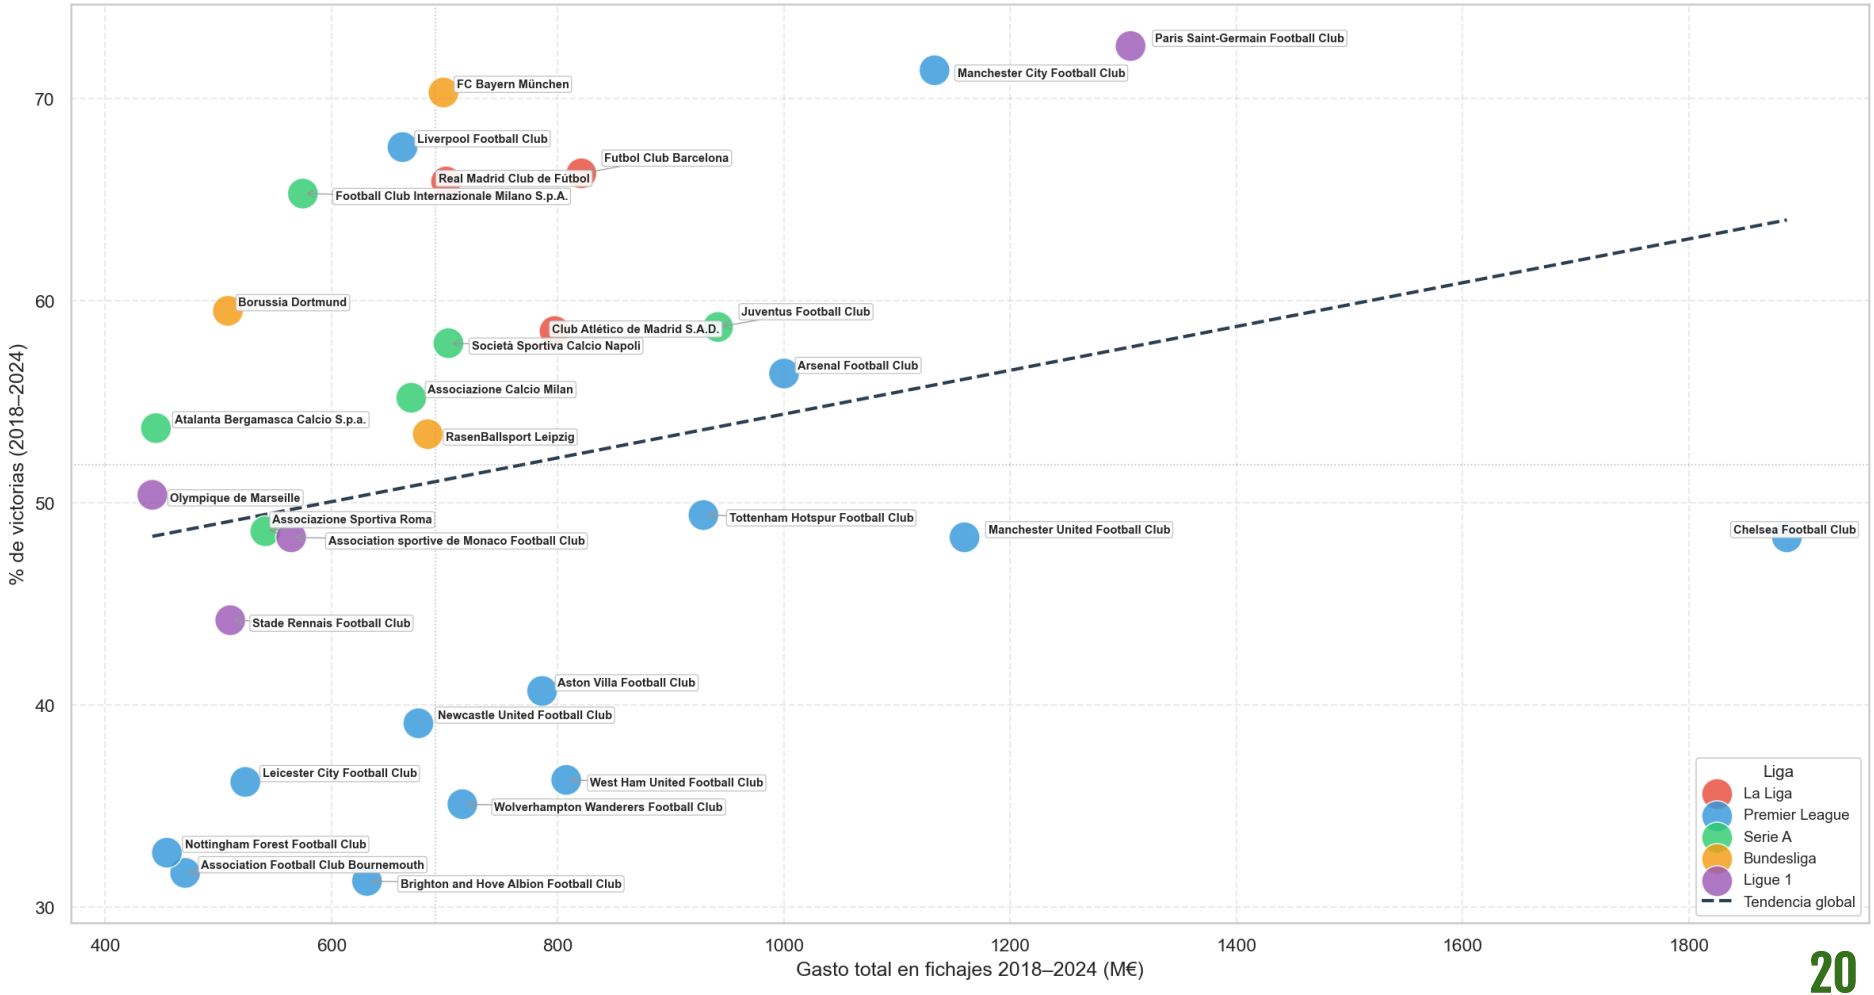

05

CONCLUSIONES

Conclusiones.

DATA WAREHOUSE

¡MUCHAS GRACIAS!